64 | 区块链技术细节：哈希算法

2018-5-10 陈皓

对于计算机来说，区块链就像一个单向链表，一个数据块中保存着三个信息。

真正的数据。

自己的地址（或是ID）。

前一个数据块的地址。

这样，通过追溯前一个块的地址，把所有的数据块存成了一条链。所以，我们叫其BlockChain。如下图所示。

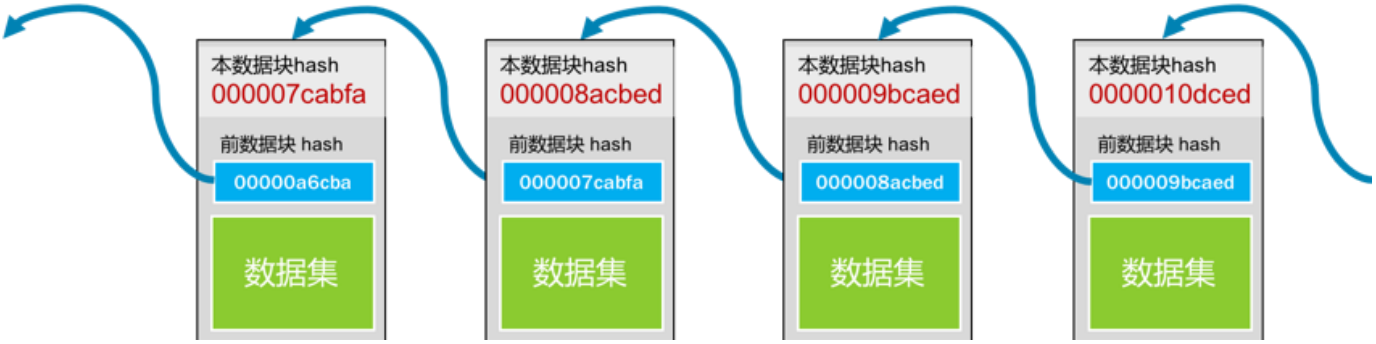

每个数据块的“地址”的编码使用了计算机上的一个算法，计算机圈内人士把这个算法叫Secure Hash。有人音译为“安全哈希”，也有人意译为“安全散列”。在计算机应用中，hash算法主要有几个功能。

用来生成唯一标识一个数据块的ID（身份证），这个ID几乎不能重复。

用来做数据的特征码。只要数据中一个bit的数据出现更改，那么整个hash值就完全不一样了。而且数据学上保证了，我们无法通过hash值反推回原数据。

于是，很多公司在互联网上发布信息或软件的时候，都会带上一个Checksum（校验码）。你只要把整个文件的数据传入到那个特定的hash算法中，就会得到一串很长的字符串。如果和官方发布的Checksum字符串不一样，那么就说明信息或文件内容被人更改或是信息残缺了。因此，也被应用在“数字签名”中。

在计算机世界里，有两个很著名的hash算法，一个叫MD5（Wikipedia链接），一个叫SHA-2（Wikipedia链接），区块链用的是SHA-256这个算法。

下面是一个示例。

> 对"chen hao"这个信息计算MD5值得到 9824df83b2d35172ef5eb63a47a878eb（一个16进制数）。
>
> 如果对 “chen hao"做一个字符的修改，将字母"o"改成数字"0” ，即 “chen ha0” ，计算出来的MD5值就成了 d521ce0616359df7e16b20486b78d2a8。可以看到，这和之前的MD5值完全不一样了。

于是，我们就可以利用hash算法的这个特性来对数据做"数字签名"。也就是说，我将"数据"和其"签名"（hash计算值）一起发布，这样可以让收到方来验证数据有没有被修改。

我们再来看上面那个区块链的图。

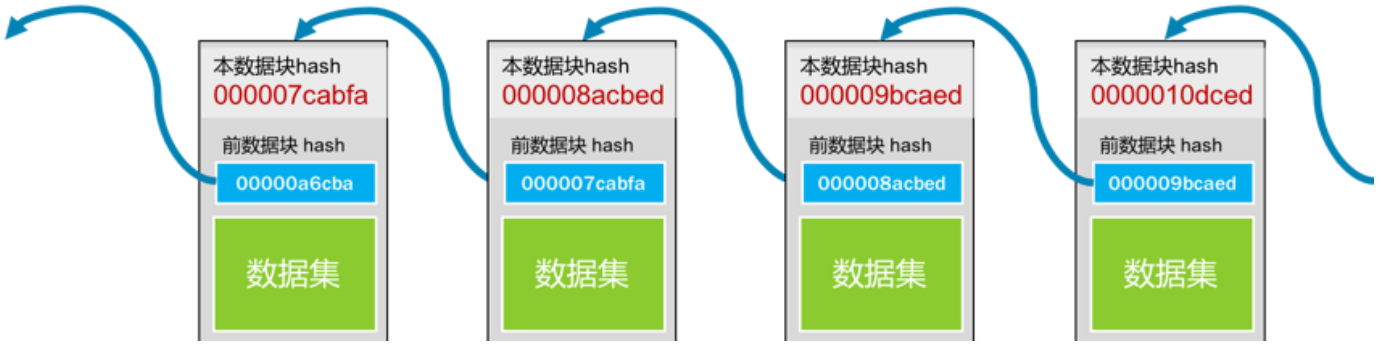

对于第一块数据，我们把其“数据集”和“前数据块的hash值 00000a6cba”一起做hash值，得到本区块的地址000007cabfa。然后，下一个区块会把自己的数据和000007cabfa一起做hash，得到000008acbed这个哈希值……如此往复下去。

根据“被hash的数据中有一个bit被修改了，整个hash就完全不一样了”这个特性，我们知道：

> 如果前置数据块中的数据改了，那么其hash就会完全不一样了，也就是说你的ID或地址就变了，于是别人就找不到这个数据块了；
>
> 所以，你还要去修改别人数据块中指向你的地址，但是别人数据块中指向你的地址（ID/hash）变了，也会导致他自己的地址（ID/hash）随之变化。因为他用你的地址生成了自己的地址，这样一来，你就需要把其他人的地址全部改掉。

在这样的连锁反应下，你想要偷偷修改一个bit的难度一下就提高很多。所以，在区块链的世界里，越老的区块越安全也越不容易被人篡改，越新的区块越不安全也越容易被人篡改。

比特币的hash算法

下面我来简单介绍一下，比特币中区块链的一些细节。下图是区块链的协议格式。

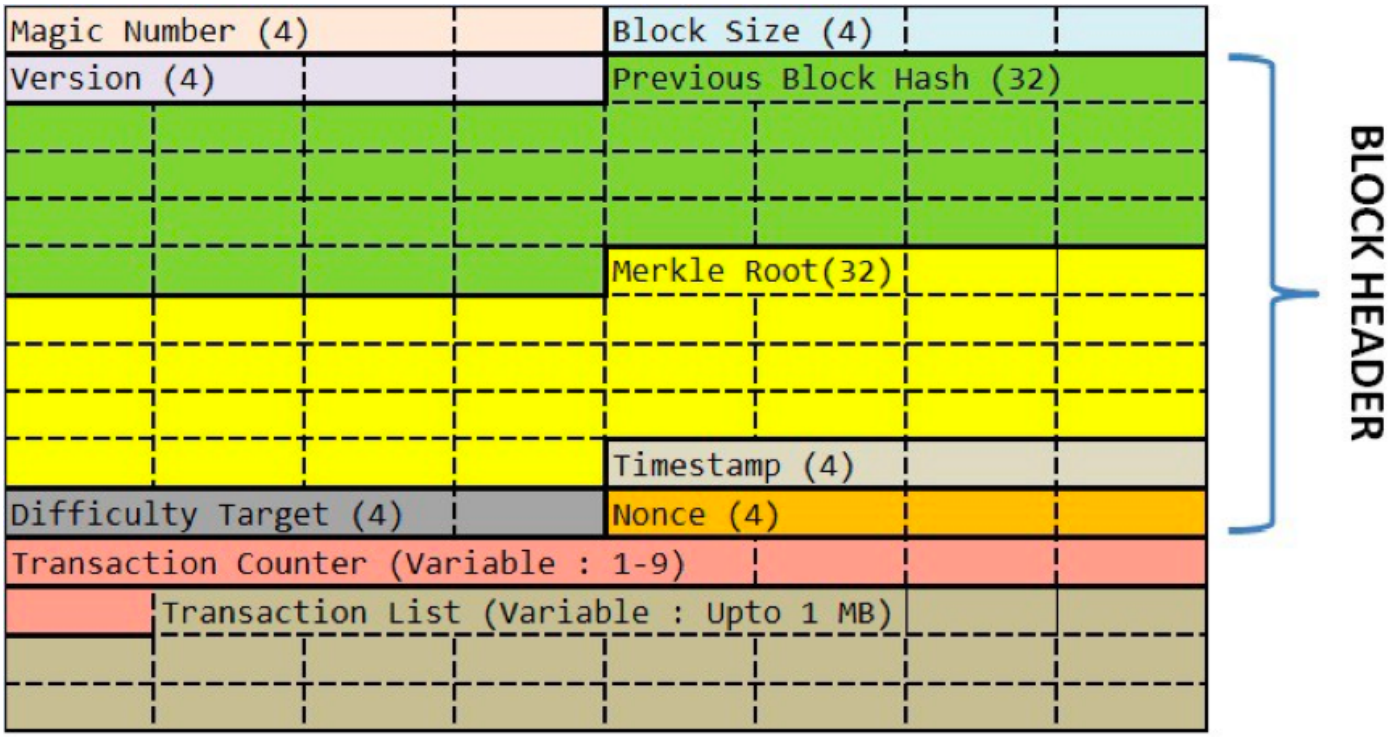

其中Version，Previous Block Hash，Merkle Root，Timestamp，Difficulty Target 和Nonce这六个数据字段是区块链的区块数据协议头。后面的数据是交易数据，分别是：本块中的交易笔数H和交易列表（最多不能超过1MB，为什么是1MB，后面会说）。

下面我来说一下区块头中的那六个字段的含义。

Version：当前区块链协议的版本号，4个字节。如果升级了，这个版本号会变。

Previous Block Hash：前面那个区块的hash地址。32个字节。

Merkle Root：这个字段可以简单理解为是后面交易信息的hash值（后面具体说明一下）。32个字节。

Timestamp：区块生成的时间。这个时间不能早于前面11个区块的中位时间，不能晚于"网络协调时间"——你所连接的所有结点时间的中位数。4个字节。

Bits：也就是上图中的Difficulty Tagrget，表明了当前的hash生成的难度（后面会说）。4个字节。

Nonce：一个随机值，用于找到满足某个条件的hash值。4字节。

对这六字段进行hash计算，就可以得到本区块的hash值，也就是其ID或是地址。其hash方式如下（对区块头做两次SHA-256的hash求值）：

```
SHA-256(SHA-256 (Block Header))
```

当然，事情并没有这么简单。比特币对这个hash值是有要求的，其要求是那个Bits字段控制的，然后你可以调整Nonce这个32位整型的值来找到符合条件的hash值。我们把这个事情叫做“挖矿”（在下一篇中，我们会详细讲一下这个事）。

关于 Merkle Root

前面说到过，可以简单地将Merkle Root理解为交易的hash值。这里，我们具体说一下，比特币的Merkle Root是怎么计算出来的。

首先，我们知道，比特币的每一笔交易会有三个字段，一个是转出方，一个是转入方，还有一个是金额。那么，我们会对每个交易的这三个字段求hash，然后把交易的hash做两两合并，再求其hash，直到算出最后一个hash值，这就是我们的Merkle Root。

我画了一个图展示一下这个过程。

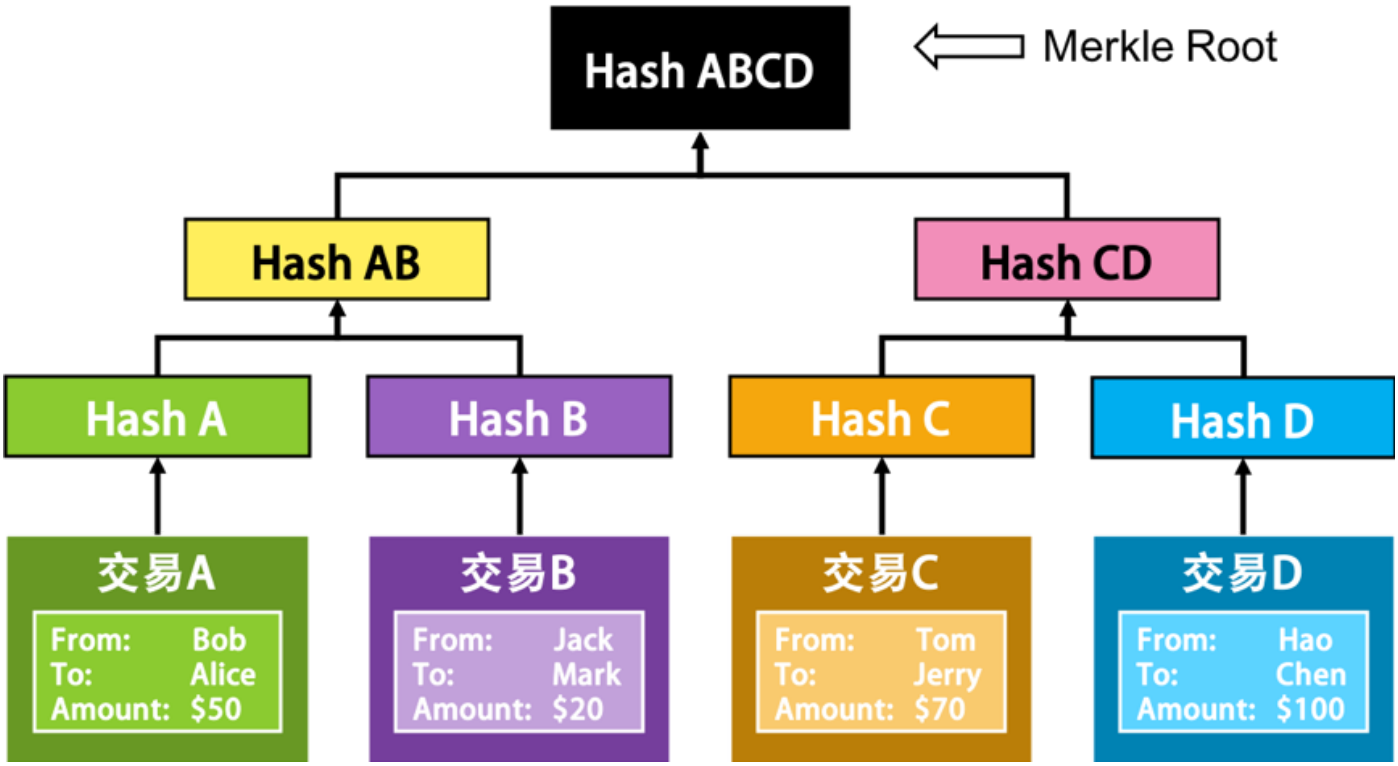

上面的示意图中有四笔交易，A和B的hash成了Hash-AB， C和D的hash成了Hash-CD，然后再做Hash-AB + Hash-CD 的hash，得到了Hash-ABCD，这就是Merkle Root。整个过程就像一个二叉树一样。

下图是一个区块链的示意图，来自比特币的白皮书。

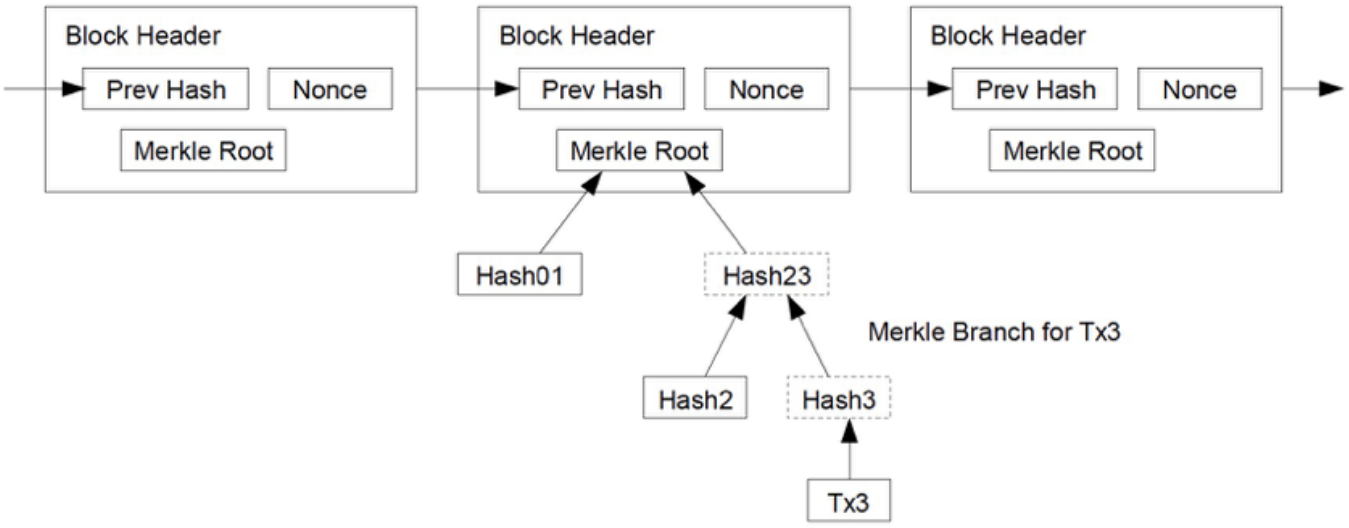

为什么要这样做呢？为什么不是把所有的交易都放在一起做一次hash呢？这不也可以让人无法篡改吗？这样做的好处是——我们把交易数据分成了若干个组。就像上面那个二叉树所表示的一样，我们可以不断地把这个树分成左边的分支和右边的分支，因为它们都被计算过hash值，所以可以很快地校验其中的内容有没有被修改过。

这至少带来三个好处。

1. 大量的交易数据可以被分成各种尺寸的小组，这样有利于我们整合数据和校验数据。
2. 这样的开销在存储和内存上并不大，然而我们可以提高校验一组数据的难易程度。
3. 在P2P的无中心化网络上，我们可以把大量数据拆成一个一个小数据片传输，可以提高网络的传输速度。

最后，需要说一下的是，以太坊有三个不同的Merkle Root树。因为以太坊要玩智能合约，所以需要更多的Merkle Root。

一个是用来做交易hash的Merkle Root。

一个是用来表示状态State的。因为一个智能合同从初始状态走到最终状态需要有若干步（也就是若干笔交易），每一步都会让合同的状态发生变化，所以需要保存合同的状态。

还有一个是用来做交易收据的。主要是用来记录一个智能合约中最终发生的交易信息。在StackExchange上的问题"Relationship between Transaction Trie and Receipts Trie"中有相应的说明，你可以前往一看。

以太坊称其为Merkle Patricia Tree（具体细节可参看其官方的Wiki）。

比特币的交易模型

比特币区块中的交易数据，其实也是一个链。为了讲清楚这个链，我们需要了解一下比特币交易中的两个术语，一个是input，一个是output，也就是交易的支出方（input）和收入方（output）。

在比特币中，一个交易可以有多个output，也就是说我可以把一笔钱汇给多个人，但一个output只能对应一个源的input，还有一个条件就是，output跟input的总数要吻合。

这里举个例子。假设，Fred给了Alice 2个比特币，Ted给了Alice 3个比特币，这个时候，Alice有5个比特币。然而，大比特币的世界里是没有余额的，所以，对于Alice来说，她只有两个没有花出去的交易，一个是2个比特币，一个是3个比特币。这在比特币中叫UTXO（Unspent Transaction Output）。

此时，如果Alice想要转给Bob 4个比特币，她发现自己的两个交易中都不够，也不能拆开之前的那两个比特币交易，那么她只能把交易2和交易3当成input，然后把自己和Bob当成output，Bob分得4个，她自己分1个。这样的交易才平衡。

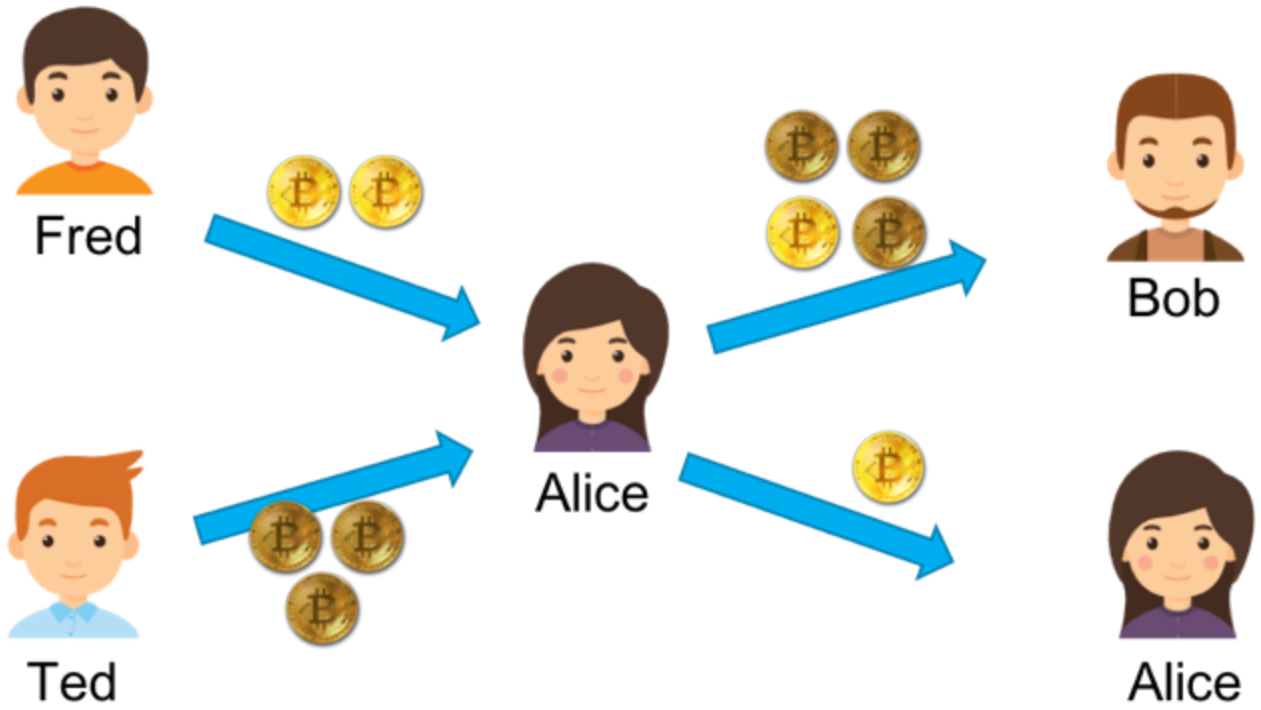

于是，一笔交易可能会包含大量的Input和Output。因为比特币没有“余额”的概念，所以需要通过多个input来凑，然后output这边还需要给自己找零，给矿工小费。

这样一来，在比特币交易中，你把钱给了我，我又给了张三，张三给了李四……就这样传递下去，形成了一个交易链。因为还没有花出去，所以就成了UTXO，而系统计算你有没有钱可以汇出去时，只需要查看一下你的UTXO就可以了。

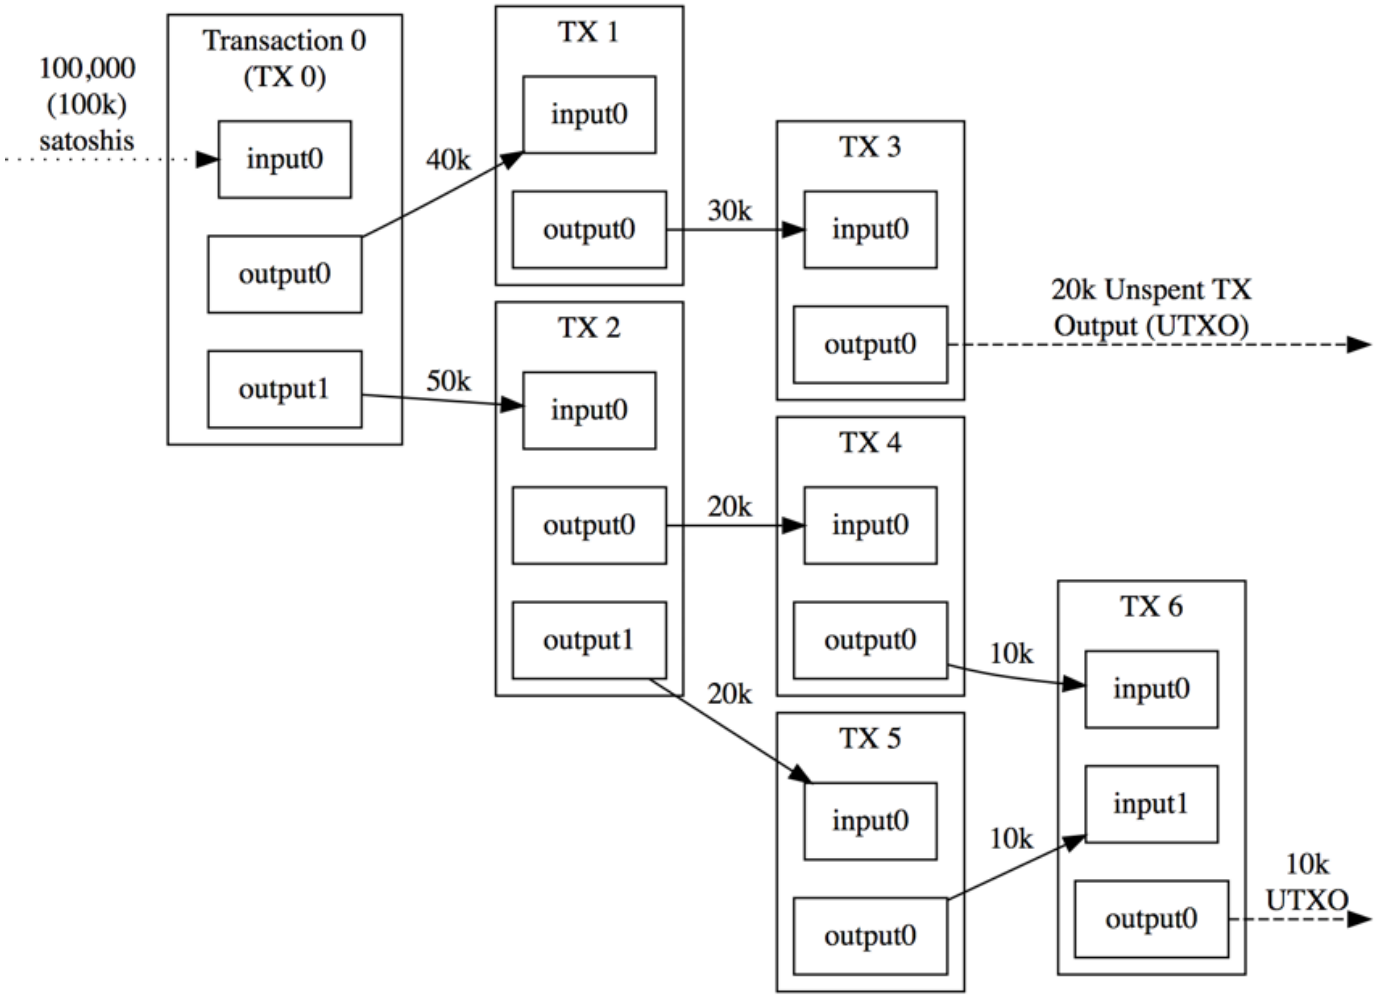

Triple-Entry Bookkeeping (Transaction-To-Transaction Payments) As Used By Bitcoin

(图片来源：https://bitcoin.org/en/developer-guide)

UTXO因为没有账户和余额的概念，所以可以并行进行多笔交易。假如你有多个UTXO，你可以进行多笔交易而不需要并行锁。然后其还有匿名性的特征，你可以隐藏自己的交易目的地（通过设置的多个output），而且没有余额意味着是没有状态的。要知道你有多少个比特币，只需要把UTXO的交易记录统计一下就可以知道了。但这也让人比较费解，而且也不利于应用上的开发。以太坊则使用了余额的方式。

在这篇文章中，我先讲述了什么是区块链以及它的核心原理是什么。随后分享了比特币的hash算法，以及Merkle Root是如何计算出来的。最后，介绍了比特币的交易模型。希望对你有帮助。（**这篇文章中图片很多，很难用音频体现出来，所以没有录制音频，还望谅解。**）

文末给出了《区块链技术》系列文章的目录，希望你能在这个列表里找到自己感兴趣的内容。

区块链的革命性及技术概要

区块链技术细节：哈希算法

区块链技术细节：加密和挖矿

去中心化的共识机制

智能合约

传统金融和虚拟货币

精选留言 30

杜小琨
1522729719

所以，为什么是1M？

作者回复 我居然写漏了……😳

1）中本聪经常在代码里放一些不说明的事，这个就是一个。

2）区块有大小限制容易理解，一个是为了更好地去中心化，因为如果尺寸下限，算力大的可以打包更多的交易，就中心化了。另一个是为了节省网络带宽。

3）为什么是1M而不是2M，这是中本聪设置的，但他并没有做出解释。

逆行
1522720923

一次交易完成后，Merkle Root 就会改变，那么每次交易都要重写整个区块链表，那效率太低了吧，是不是我错过了什么细节？

作者回复 Merkle Root 是一组交易的层层hash的结果。

Nelson
1522723247

"假如你有多个 UTXO，你可以进行多笔交易而不需要并行锁。"这一句没懂，不会出现一个UTXO被使用两次情况吗？

作者回复 不同的交易在不同的UTXO上并行，在同一个上不行。如果用余额来做，则无法并行，上一笔不完成，下一笔无法执行。

登高
1524966549

“”对这五字段进行 hash 计算，就可以得到本区块的 hash 值“”

数了下，前面介绍了6个，这里写的五个，是笔误吗？

jimmy
1522727529

近期在研究event-sourcing架构，比特币的交易感觉有点像event-sourcing的味道，记录的只是事件，无状态，天然适应分布式，不知道这个类比是否有点牵强

作者回复 是很牵强

多米

1522718906

然而对比特币没兴趣

痴痴

1529994546

本区块的Id值等于 【version、previous block hash、merkle root、timestamp、bits、nonce】hash计算而得到的，而merkle是交易两两hash得到的，假如产生一笔新交易，merkle root的值肯定就会改变，区块Id的值不就也会跟着变吗？那您是怎么得出【merkle和区块无关】的结论呢？？

neohope

1529664304

建议补充一下ETH和BITCOIN的一些不同啦，比如ETH是有世界状态的，而比特币只有UTXO。比如BITCOIN也是通过脚本来完成交易的，ETH通过EVM来让大家都可以写智能合约。比如ETH发明了Gas，积极推送DAO、DAPP什么的，会不会好一些？

Donald

1523699421

为什么是对区块头做两次 SHA-256 的 hash 求值？

吴天

1523320670

UTXO不太理解 我有多少可交易的比特币是系统从哪里验证的？从区块链追溯下去还是另外有一个存储记录？

郎哲

1522717506

赞赞赞讲的通俗易懂

edisonhuang

1564446684

区块链的核心原理是针对每一个区块，内容都包含本身数据，上一个区块的id，以及利用

id+数据计算的区块本身的id。由于id计算基于内容生成，当数据中任何一个bit改了就会导致完全不同的id，而所有的区块是像链表一样彼此链接，改变自己还要改变自己后面的子孙，因此可以让数据不易更改

永光
1531403889

区块链的协议格式，这部分数据是存在区块链图（本区快hash地址，前一个区块hash地址，数据）中的数据中吗？总感觉不太对？不知道协议格式具体在哪里存着？

痴痴
1529913208

1.是不是只有前一个区块交易满了，才会产生下一个区块？ 2.Merkle的生成过程理解，不过不理解的是：假设a区块有新的一笔交易产生，放到这个区块里，那么这个区块的id自然也就变了，后面所有的区块id也要跟着变，这样是不是太麻烦了

> 作者回复 1、不是，这个由各个矿工自己决定。2、merkle和区块无关，但是与交易有关。

i
1528014673

既然一个区块可以存放至多四千笔交易，那什么时候才能生成新区块？够四千笔交易还是其他别的生成逻辑？

龚极客
1524097013

Merkle Root是否至多三层？因为每个hash4个字节*7 =28<32 。如果这样，那么超过3层怎么处理？

> 作者回复 没有啊，hash无论hash多长的字符，总是得到一样的长度。你说的 “hash4个字节*7=28” 是什么意思？

怀兵
1524011909

关于以太坊state存储的部分有点模糊，表达成是账户状态的存储，而非合同状态，可能更好

一些

总指挥
1523596941

生成Merkle Root 过程理解的，但它的目的还是不能理解，如果是要验证完整性为什么不直接全部tx来哈希？小弟不才，望各位解答。

作者回复 文中已经讲了。可以分块整理

湖心亭看雪
1522915228

同问为什么是1M?

Y024
1522902825

下载软件通过校验码验证真伪这个小常识，可以避免很多李鬼事件，就值回票价。

作者回复 好习惯

Dylan
1522836671

最近在研究ETH的MPT树，看到这豁然开朗很多了

浪迹天涯
1522810230

期待下一期的挖矿的技术细节，HashCash和命中概率问题。

wx
1522798638

浅显易懂，点赞

风的叹息

1522754641

单笔交易和区块是什么关系？记录在数据集里面之一？然后同时进行的交易呢？广播，这里的时序问题怎么处理的，不知后文有没解答

> 作者回复 一个区块里有多笔交易，一个区块最大1M，一笔交易平均250个字节，于是一个区块4000笔交易，一个区块平均生成时间10分钟，所以每秒6.66667笔交易。
>
> 交易没有时序问题，因为一笔交易的支出必需来自（Unspent Transaction Output），所以，如果你无法对同一个“未花交易”操作两次，而对一个“未花交易”的操作未被确认前是不会产生新的未花交易，于是你也就无法进行下笔操作。
>
> 广播的时序？为什么会有时序问题呢？一个区块里有前一个区块的地址，另外，算力太大了，10分钟才能产生一个，完全是超低并发应用。

邋邋遢遢

1522739461

通过作者对UTXO做出的例子，又对它有了深刻的理解。而且对merkle树也明白了许多。很棒！

0bug

1522735976

比特币交易模型中input应该是收入方，output是支出方吧

> 作者回复 对于交易来说，input是交易的输入方，output是交易的输出方。

jimmy

1522727300

区块链的介绍看过些英文资料，懵懵懂懂，有耗子哥的文章提炼，豁然开朗，看着踏实，必须赞

龍蝦

1522722015

Merkle Root 还是不太理解，有没更详细的资料呢？

作者回复 就是简单的hash啊，怎么个不理解？

云学

1522719555

真心好懂，功力深厚才能写出这种文章

Geek_74f253

1522719294

如果区块有新增的数据是不是所有的区块也需要重新计算一遍hash呢

作者回复 一般来说不需要